


**INTRODUÇÃO
À CIÊNCIA
DE DADOS**

ANO 2024/2025



O impacto da Inteligência Artificial na investigação científica

Magda Matias^a e Rita Gonçalves^b

^aMestrado em Ciência de Dados para Ciências Sociais

^bDisciplina isolada

Resumo

A Inteligência Artificial (IA) é uma tecnologia que está a ser amplamente aplicada em várias áreas. A investigação científica é uma das áreas que poderá ser mais significativamente impactada pela IA, pelo potencial que ela significa no aceleração da descoberta científica, no aumento da eficácia e do ritmo dos processos de investigação (European Commission, 2024). Para além das vantagens que pode significar, o uso de ferramentas de IA também origina preocupações, levantando questões relacionadas com a ética e a transparência na investigação científica.

O objetivo deste trabalho é fazer uma recolha de literatura científica que aborde o impacto da IA na investigação científica e a partir desse conjunto de documentos efetuar uma análise bibliométrica e uma análise de conteúdo. O trabalho envolveu quatro etapas principais: (i) definição do tema e pesquisa na base de dados Scopus, (ii) análise bibliométrica e de conteúdo dos resultados em ambiente Python, (iv) desenvolvimento de um painel de informação para visualização dos dados.

Os resultados evidenciam um aumento do número de documentos científicos que abordam a aplicação de modelos de IA nos processos de investigação científica nos últimos quatro anos. As áreas temáticas mais representadas nos documentos são a Ciência da Computação, a Engenharia, as Ciências Sociais e a Medicina. A análise de conteúdo permitiu concluir que o conjunto de dados contempla estudos relacionados com o impacto da aplicação de processos automáticos e de modelos de IA, abordando também a análise de dados e o desenvolvimento de modelos de aprendizagem automática e sistemas de informação.

Palavras-chave: Inteligência Artificial, investigação científica, análise bibliométrica, análise de conteúdo.

1. Introdução e enquadramento do tema

O conteúdo central do presente texto encontra-se estruturado em quatro partes. A primeira parte é dedicada à contextualização do tema escolhido, a segunda aborda a metodologia usada no decurso do trabalho, a terceira foca-se nos resultados, quer da análise bibliométrica, quer da análise de conteúdo e, por fim, a última parte apresenta uma reflexão final sobre o tema e as conclusões do trabalho.

A IA é um assunto muito abordado nos dias de hoje. Têm sido produzidos e divulgados diversos conteúdos, desde reportagens televisivas e *podcasts*, até livros, artigos e palestras, sobre o impacto do desenvolvimento da IA no presente e no futuro da nossa sociedade.

Uma das áreas que poderá ser mais significativamente impactada pela IA é a investigação científica, pelo potencial que ela significa no aceleração da descoberta científica, no aumento da eficácia e do ritmo dos processos de investigação (European Commission, 2024). A IA é utilizada pelos cientistas para gerar hipóteses, conceber experiências, recolher e interpretar dados de formas que anteriormente não eram possíveis apenas com os métodos tradicionais (Erduran & Levrini, 2024). Para além das vantagens que pode significar, o uso de ferramentas de IA também origina desafios e preocupações, levantando questões relacionadas com a ética, os direitos de autor, a transparência, a privacidade de dados e a integridade da investigação (Gouveia, 2024).

Assim, o presente trabalho foca-se no cruzamento destes dois assuntos, ou seja, no impacto, em sentido lato, da IA na investigação científica, procurando saber de que forma está a ser abordado pela comunidade científica. Este objetivo último prevê o cumprimento de objetivos intercalares: a pesquisa bibliográfica sobre o tema e o estudo desses resultados por meio de metodologias de análise bibliométrica e de conteúdo.

A escolha do tópico da IA deveu-se, portanto, à presença frequente do mesmo na sociedade atual, originando preocupação, dúvida e desconfiança, mas também entusiasmo e interesse. Por ser um tema tão presente, consideramos útil participar nesse exercício de pesquisa e reflexão sobre os impactos da IA. Optámos por cruzar este primeiro tópico com o da investigação científica, por estarmos inseridas numa instituição de ensino e investigação.

2. Metodologia

A primeira etapa para a realização deste trabalho foi a definição da temática, a seleção da fonte de informação e a expressão de pesquisa a usar. O enunciado do tema do trabalho ficou definido para o impacto da IA na investigação científica.

Como fonte de informação para a pesquisa bibliográfica foi selecionada a base de dados de publicações científicas Scopus, que tem um carácter referencial e multidisciplinar e uma cobertura mundial.

Para a pesquisa bibliográfica foram usados os termos "artificial intelligence", "scientific research" e "impact*", resultando na seguinte expressão de pesquisa: (TITLE-ABS-KEY("artificial intelligence") AND TITLE-ABS-KEY("scientific research") AND TITLE-ABS-KEY("impact*")).

Esta pesquisa recuperou um total de 243 documentos que foram exportados em formato .csv. Com base neste conjunto de dados foram desenvolvidas técnicas de análise bibliométrica, de limpeza e processamento dos dados, de mineração de texto e modelação em ambiente Python, com recurso a várias bibliotecas. O objetivo da aplicação destes métodos e técnicas foi o de extrair conhecimento dos dados e dessa forma identificar os autores, as áreas temáticas, os contextos geográficos e os tópicos mais relevantes dentro da temática.

2.1. Análise bibliométrica

A análise bibliométrica estruturou-se em quatro partes, correspondendo cada uma delas a uma pergunta e a um conjunto de tendências analisadas:

Quantos?

Análise de contagens e distribuição de documentos por autores, número de citações, nível de acesso e área temática.

Quando?

Análise das tendências ao longo do tempo em termos de volume de publicação, número de citações e nível de acesso.

Onde?

Análise das fontes, instituições/afiliações e locais de publicação mais representados de forma a compreender onde se concentra a investigação.

O quê?

Análise dos tipos de documentos, palavras-chave e termos de pesquisa mais frequentes.

Para estas análises recorreram-se às seguintes bibliotecas em ambiente Python através do Jupyter Notebook:

Pandas: para manipulação e análise de dados.

NumPy: para operações com matrizes e funções matemáticas.

Geopandas: para trabalhar dados geoespaciais.
Matplotlib: para criação de gráficos.
Seaborn: para visualização de dados estatísticos.
Wordcloud: para criar nuvens de palavras.

2.2. Análise de conteúdos

Para a análise de conteúdo foram em primeiro lugar aplicadas técnicas de pré-processamento. Os primeiros processos a aplicar tiveram como objetivo a uniformização de texto: conversão de texto em minúsculas; remoção de caracteres especiais, números, espaços em branco, hiperligações e etiquetas HTML; desdobramento das contrações.

Foi também efetuada uma *tokenização* básica dos textos dos resumos, de forma a preparar os dados para a análise de texto com recurso a algoritmos de Processamento de Linguagem Natural (PLN). Este processo separou os textos em palavras e criou uma coluna no *data frame* com uma lista de palavras.

De seguida foi feita a remoção de *stopwords*, ou seja, palavras comuns consideradas pouco significativas na análise do texto, com base na lista de *stopwords* padrão do *Natural Language Toolkit* (NLTK) e de uma lista adicional de *stopwords* contendo palavras na forma negativa. Uma vez que a análise tem um caráter neutro e se foca em temas/tópicos gerais, considerou-se que as palavras negativas poderiam acrescentar ruído.

De forma a contribuir para uma maior precisão dos modelos de PLN, reduzindo variações, foi aplicada a técnica da lematização, que faz a conversão das palavras para a sua forma canónica. Para a lematização foi usado o modelo de linguagem da biblioteca *SpaCy*.

Foi considerada a aplicação de outras técnicas, designadamente a *stemização*, que procede à redução das palavras à sua raiz, removendo sufixos. No entanto, considerou-se que a técnica da lematização poderia contribuir para uma melhor compreensão do texto uma vez que preserva melhor a integridade das palavras.

Neste processo optou-se por separar as palavras hifenizadas das não hifenizadas, de forma a aplicar a lematização apenas ao segundo grupo de palavras. Desta forma foi possível manter as palavras hifenizadas na sua forma original, evitando que as mesmas fossem separadas em duas palavras diferentes.

Na última etapa do pré-processamento foi feita uma remoção adicional de palavras consideradas pouco significativas no contexto desta análise de texto, nomeadamente as palavras da expressão de pesquisa ('impact', 'artificial', 'intelligence', 'scientific', 'research') e outras pouco relevantes/significativas que se destacaram no gráfico das 30 palavras mais

frequentes ('ai', 'use', 'provide', 'author', 'also'). A remoção das palavras da expressão de pesquisa foi realizada com o intuito de realçar os tópicos dentro do grande tema/tópico pesquisado.

Após o pré-processamento, iniciou-se a etapa da vectorização com a aplicação de técnicas de transformação de texto em bruto num formato passível de ser compreendido por algoritmos de aprendizagem automática, ou seja, em vetores numéricos.

Em primeiro lugar foi feita a vetorização dos dados mediante a técnica *Bag-Of-Words*, que envolve a conversão de cada documento num vetor e a representação da frequência de cada palavra única, não tendo em conta a ordem das palavras e concentrando-se apenas na sua ocorrência.

Foi também aplicada a técnica de vetorização dos dados com base em bigramas. Ao contrário da técnica *Bag-Of-Words*, os N-gramas não consideram cada palavra de forma independente e sim uma sequência de palavras, neste caso, pares de palavras consecutivas. Desta forma, obtém-se mais algum contexto.

Por fim, dentro da etapa da vectorização, foi aplicada a técnica *Term Frequency-Inverse Document Frequency* (TF-IDF), que vai além do modelo *Bag-Of-Words* uma vez que tem em conta não só a frequência de uma palavra num determinado documento (*Term Frequency*), mas também o grau de exclusividade da palavra em todos os documentos (*Inverse Document Frequency*). Assim, esta técnica é útil para a análise porque atribui um peso maior às palavras que são mais informativas.

Na parte da modelação o foco foi a identificação de dimensões latentes nos textos, resultando num conjunto de temas/tópicos. Para tal, foram aplicadas funções da biblioteca *Gensim* e depois foi executado o modelo *Latent Dirichlet Allocation* (LDA).

A segunda parte da modelação é dedicada à definição e análise de *clusters*, nomeadamente a partir dos tópicos identificados. O número ideal de *clusters* foi fixado em seis através do "Método do Cotovelo", no qual se executa o algoritmo *K-means*. Através da extração de distribuição de tópicos para cada documento identificaram-se os três documentos mais relevantes em cada tópico. Para a redução da dimensionalidade recorreu-se à biblioteca *Scikit-learn* e à técnica *Principal Component Analysis* (PCA). Depois foi calculada a distribuição média de tópicos para cada *cluster*.

3. Resultados e Discussão

3.1. Análise bibliométrica

Através da análise bibliométrica é possível perceber que entre os anos de 1990 e 2019 existem documentos sobre o tema, mas em número bastante reduzido. A partir de 2020 começa-se a verificar um aumento, atingindo já um valor de dois dígitos (11). Contudo, é entre os anos de 2021 e 2024 que o número aumenta significativamente, atingindo um pico no ano de 2024 com 91 documentos. Por esta evolução percebe-se o crescimento exponencial da IA na investigação científica nos últimos anos e de forma muito evidente no último ano.

Quanto à distribuição geográfica da produção científica destaca-se a China com 66 documentos associados, revelando o seu avanço relativamente a este tema. Com o segundo valor mais elevado encontram-se os Estados Unidos da América com 37 documentos.

O artigo com mais citações tem o título “ChatGPT and the rise of large language models: the new AI-driven infodemic threat in public health”, um título bastante ilustrativo da influência que modelos de IA podem ter na sociedade.

As áreas temáticas mais representadas nos documentos são Ciência da Computação, Engenharia, Ciências Sociais e Medicina.

Quanto à tipologia de documento a mais frequente é artigo, seguida dos documentos associados a conferências académicas e científicas.

As palavras-chaves de indexação atribuídas aos documentos que se revelaram mais frequentes são: “artificial intelligence”, “scientific researches”, “human”, “machine learning” e “deep learning”. Conclui-se que o conjunto de documentos recuperados tem um grande foco na aplicação de modelos de IA, de algoritmos de aprendizagem por máquina e de redes neurais artificiais complexas em investigações científicas.

3.2. Análise de conteúdo

Nesta secção destacam-se alguns dos principais resultados da análise de conteúdo.

Do gráfico dos bigramas mais comuns destacam-se os seguintes: *big data*, *machine learn*, *neural network*, *boron nitride*, *decision making*, *information technology*, *nitride fiber*. Através destes resultados reforça-se mais uma vez a forte presença de métodos de aprendizagem por máquina e de redes neurais, frequentemente utilizados para a análise de grandes quantidades de dados, importante para a tomada de decisões.

O gráfico do TF-IDF mostra-nos que as palavras mais comuns são: *technology*, *model*, *data*, *study*, *system*, *science*, *chatGPT*, *development*, *new*, *application*.

Da execução do modelo LDA resultou um conjunto de seis tópicos com a associação das quatro palavras mais relevantes em cada um deles:

Topic 0: technology + science + information + paper

Topic 1: datum + model + paper + big

Topic 2: study + chatgpt + technology + ethical

Topic 3: technology + system + development + application

Topic 4: technology + model + water + datum

Topic 5: technology + study + development + analysis

Para cada um dos tópicos fez-se um exercício de atribuição de um rótulo e uma breve descrição:

- Tópico 0: Tecnologia e Ciência da Informação: relação entre tecnologia, ciência e gestão de informação em áreas como a medicina e a publicação científica.
- Tópico 1: *Big data* e modelos: análise de grandes conjuntos de dados e de modelos.
- Tópico 2: Inteligência Artificial e ética: estudos sobre questões éticas e o impacto de tecnologias e modelos de IA, como o ChatGPT.
- Tópico 3: Sistemas tecnológicos: desenvolvimento e aplicação de sistemas inteligentes e de modelos de aprendizagem automática.
- Tópico 4: Modelos tecnológicos: estudo e aplicação de tecnologias na gestão de recursos hídricos, com base em dados científicos.
- Tópico 5: Estudos tecnológicos: análise de dados e tecnologias emergentes em áreas científicas ligadas com a educação e a informação.

Através da extração de distribuição de tópicos para cada documento foi possível identificar e examinar alguns documentos que estão fortemente associados a cada tópico e confirmar se os tópicos fazem sentido para esses documentos.

A análise das dimensões latentes e o desenvolvimento de uma descrição para cada tópico identificado foi favorecida pela complementaridade da análise das nuvens de palavras associadas a cada um dos tópicos e dos três documentos mais relevantes em cada um deles.

Os resultados da definição de *clusters* coincidentemente também foram seis *clusters*. Este resultado sugere que tanto os tópicos como os *clusters* possuem uma estrutura bem delineada em torno dos dados analisados.

O mapa de calor da distribuição média de tópicos por *cluster* permitiu fazer a seguinte correspondência:

- *cluster 0* - tópico 4;
- *cluster 1* - tópico 2;
- *cluster 2* - tópico 3;
- *cluster 3* - tópico 1;
- *cluster 4* - tópico 5;
- *cluster 5* - tópico 0.

3.3 Análise e comunicação de resultados

Com base na informação recolhida e analisada (dados bibliométricos e de conteúdo) procedeu-se ao desenho e implementação de um painel de informação (*dashboard*) onde se apresentam as mensagens principais deste trabalho de forma simples, intuitiva e interativa. O conteúdo do painel foi pensado para proporcionar uma perspetiva geral do conjunto de dados extraído e analisado sobre o tema, comunicando os seus pontos-chave. A navegação e a consulta dos conteúdos foram pensadas para serem o mais intuitivas possível e para permitir que o leitor possa alterar os parâmetros de visualização dos dados, selecionando um ano ou um país específico, por exemplo.

Este painel de informação foi construído a partir da plataforma / biblioteca Streamlit.

4. Reflexões finais

Os resultados permitem-nos concluir que o conjunto de dados contempla estudos relacionados com a aplicação de processos automáticos, abordando nomeadamente os impactos desses processos na eficiência da investigação científica. Destacam-se os métodos ligados com a aprendizagem por máquina e métodos de aprendizagem por máquina (*machine learning*) e de redes neurais (*deep learning*).

No conjunto de dados é também abordado o recurso a modelos de Inteligência Artificial, respetivos impactos e questões de natureza ética.

Algumas das áreas científicas que se destacaram ao longo da análise de conteúdo foram as ciências de computação e de informação, a medicina e os estudos climáticos.

Outro tópico frequentemente abordado no conjunto de dados é a análise de dados científicos, sobretudo *big data*, e o desenvolvimento de modelos de aprendizagem automática, sistemas e tecnologias de informação úteis para gestão de informação, previsões ou tomada de decisões.

O tema da IA na investigação científica tem tido um grande crescimento nos últimos anos. A pesquisa mostrou-nos que os impactos e a influência que a IA está a ter no campo da investigação científica verificam-se sobretudo ao nível do uso deste tipo de tecnologia nos processos de investigação. Verifica-se também que já existem estudos sobre os impactos dessa utilização no campo da investigação e da sociedade em geral.

5. Bibliografia

Erduran, S., & Levrimi, O. (2024). The impact of artificial intelligence on scientific practices: an emergent area of research for science education. *International Journal of Science Education*. <https://doi.org/10.1080/09500693.2024.2306604>

European Commission. (2024). *Living guidelines on the responsible use of generative AI in research*. European Union. https://research-and-innovation.ec.europa.eu/document/2b6cf7e5-36ac-41cb-aab5-0d32050143dc_en

Gouveia, L. B. (2024, December 5). *Inteligência Artificial e investigação científica*. Dia do Investigador. Centro de Estudos Organizacionais e Sociais do Politécnico do Porto. CEOS.PP Diceo24. <https://bdigital.ufp.pt/handle/10284/13391>